Corrección del sesgo de selección por *trigger* en la asimetría azimutal A_1 mediante verosimilitud

Notas de trabajo a partir de la Tesis de Licenciatura de L. Silva (cap. 6)

16 de octubre de 2026

Resumen

En la tesis, la asimetría temprano–tardío del número de muones en los tanques del SD se invierte en el *far-core* ($A_1 = -0.124 \pm 0.019$ en 1200–1350 m) cuando el promedio se restringe a las estaciones que forman parte del evento reconstruido, mientras que sobre todas las estaciones simuladas es positiva ($+0.069 \pm 0.016$). Estas notas formulan el problema como una probabilidad condicional no tenida en cuenta, muestran con el teorema de Bayes por qué el promedio condicionado está sesgado, y construyen dos verosimilitudes (truncada y censurada) que incorporan explícitamente el mecanismo de selección y recuperan el A_1 físico. Un Monte Carlo de juguete, ajustado para reproducir las fracciones de retención de la tesis, reproduce la inversión ($\hat{A}_1 = -0.098$) y muestra que la verosimilitud censurada la corrige ($\hat{A}_1 = +0.070 \pm 0.015$ para $A_1^{\text{verd}} = 0.07$).

1. El problema como probabilidad condicional

Sea una estación del arreglo en un bin (r, θ, E), con fase azimutal ϕ en el plano de la lluvia. Llamamos

- N: número de muones que atraviesan el detector (el observable cuya asimetría se busca);
- $T \in \{0, 1\}$: la estación disparó y forma parte del evento reconstruido (`HasStation`); resume disparo, lectura y reconstrucción;
- $\boldsymbol{x} = (r, \phi, \theta, E)$: covariables geométricas, conocidas para *toda* estación del arreglo, haya disparado o no.

Lo que se quiere medir es $\mu(\phi) = \mathbb{E}[N \mid \boldsymbol{x}]$, modelado como

$$\mu(\phi) = \bar{\mu}(r, \theta, E)\,(1 + A_1 \cos\phi). \tag{1}$$

Lo que se midió es $\mathbb{E}[N \mid \boldsymbol{x}, T = 1]$. Por Bayes,

$$P(n \mid \boldsymbol{x}, T = 1) = \frac{P(T = 1 \mid n, \boldsymbol{x})\, P(n \mid \boldsymbol{x})}{P(T = 1 \mid \boldsymbol{x})}, \tag{2}$$

y por lo tanto

$$\mathbb{E}[N \mid \boldsymbol{x}, T = 1] = \frac{\mathbb{E}\big[N\, \varepsilon(N, \boldsymbol{x})\big]}{\mathbb{E}\big[\varepsilon(N, \boldsymbol{x})\big]} = \mu(\phi) + \frac{\mathrm{Cov}\big(N, \varepsilon(N, \boldsymbol{x}) \mid \boldsymbol{x}\big)}{\bar{\varepsilon}(\boldsymbol{x})}, \tag{3}$$

con $\varepsilon(n, \boldsymbol{x}) \equiv P(T = 1 \mid N = n, \boldsymbol{x})$ la **eficiencia de selección** y $\bar{\varepsilon}(\boldsymbol{x}) = \sum_n \varepsilon(n, \boldsymbol{x}) P(n \mid \boldsymbol{x})$ la fracción de estaciones retenidas.

El segundo término de (3) es el sesgo. Es nulo si la selección no depende de N, y es positivo si las estaciones con más muones disparan más. Lo decisivo para A_1 es que **depende de** ϕ: la eficiencia depende también de la componente electromagnética,

$$\varepsilon(n, \boldsymbol{x}) = \sum_{n_{EM}} P(T = 1 \mid n, n_{EM})\, P(n_{EM} \mid \boldsymbol{x}), \tag{4}$$

y $\mathbb{E}[n_{EM} \mid \boldsymbol{x}]$ es mayor del lado temprano. Del lado temprano la EM casi satura el disparo, ε depende poco de n y el sesgo es chico; del lado tardío ε crece fuertemente con n, $\bar{\varepsilon}$ es chica y el sesgo es grande. Si el sesgo tardío supera a $\mu_{\text{temp}} - \mu_{\text{tard}}$, el signo de A_1 se invierte sin que se haya movido ningún muón.

Nombre del efecto. Es un sesgo de selección de tipo *supervivencia* (sólo se promedian las estaciones que "sobrevivieron" al filtro, y la supervivencia depende de la cantidad medida). Más precisamente, T es un *colisionador* de N y N_{EM}: condicionar en $T = 1$ induce una anticorrelación entre ambos entre las estaciones retenidas (paradoja de Berkson), y como N_{EM} depende de ϕ, el sesgo es diferencial en azimut. El análogo astrofísico más cercano es el sesgo de Malmquist de las muestras limitadas en flujo. En el lenguaje de datos faltantes, el conteo falta *no al azar* (MNAR): la probabilidad de que falte depende del propio valor faltante.

2. Dos verosimilitudes que incorporan la selección

Sea $P(n \mid \lambda)$ el modelo de conteo (por ejemplo Poisson con $\lambda_i = \mu(\phi_i)\, a_i$, donde a_i es el área efectiva) y $\boldsymbol{\vartheta} = (\bar{\mu}, A_1)$ los parámetros de interés. Sea S el conjunto de estaciones seleccionadas ($T_i = 1$) y $\bar{S}$ el de las no seleccionadas.

2.1. Verosimilitud truncada (sólo estaciones seleccionadas)

Si sólo se usan las estaciones seleccionadas, cada una debe entrar con su distribución *condicionada* a haber sido seleccionada:

$$\mathcal{L}_{\text{trunc}}(\boldsymbol{\vartheta}) = \prod_{i \in S} \frac{P(n_i \mid \lambda_i)\, \varepsilon(n_i, \boldsymbol{x}_i)}{\bar{\varepsilon}(\lambda_i, \boldsymbol{x}_i)}, \qquad \bar{\varepsilon}(\lambda, \boldsymbol{x}) = \sum_n P(n \mid \lambda)\, \varepsilon(n, \boldsymbol{x}). \tag{5}$$

El factor $\varepsilon(n_i, \boldsymbol{x}_i)$ del numerador no depende de $\boldsymbol{\vartheta}$ y puede omitirse en la maximización; toda la corrección está en el denominador $\bar{\varepsilon}$. No requiere saber qué estaciones no dispararon, pero depende enteramente de la *forma* de $\varepsilon(n, \boldsymbol{x})$.

2.2. Verosimilitud censurada (completa)

Las estaciones que no dispararon no tienen conteo, pero *existen* y su no-disparo es información: indica que su N fue probablemente bajo. Incluyéndolas como observaciones censuradas,

$$\mathcal{L}_{\text{cens}}(\boldsymbol{\vartheta}) = \prod_{i \in S} P(n_i \mid \lambda_i)\, \varepsilon(n_i, \boldsymbol{x}_i) \prod_{j \in \bar{S}} \Big[1 - \bar{\varepsilon}(\lambda_j, \boldsymbol{x}_j)\Big]. \tag{6}$$

Requiere conocer, evento a evento, la lista de estaciones *activas* en el bin (no confundir una estación que no disparó con una estación fuera de adquisición), cosa que el SD registra. Al usar más información es más eficiente que (5) y, como se ve en la Sec. 5, bastante más robusta frente a errores en el modelo de ε: la fracción observada de estaciones retenidas en cada ϕ restringe directamente a $\bar{\varepsilon}$.

2.3. Implementación práctica

Como μ y ε dependen de ϕ sólo a través de $\cos\phi$, basta con agregar los datos en bines finos de $\cos\phi$: para cada bin k se guardan el histograma H_{nk} de conteos de las estaciones seleccionadas y el número U_k de estaciones no seleccionadas. Entonces

$$-\ln \mathcal{L}_{\text{cens}} = -\sum_k \Big[\sum_n H_{nk} \ln P(n \mid \lambda_k) + U_k \ln\big(1 - \bar{\varepsilon}_k\big) \Big] + \text{cte}, \tag{7}$$

que se minimiza en $(\bar{\mu}, A_1)$ en milisegundos. Con varios bines radiales o cenitales, $\bar{\mu}$ va por bin y A_1 puede parametrizarse en (r, θ).

3. Extensión al UMD

Para el UMD, la selección no actúa sobre el conteo del módulo enterrado, N_U, sino sobre el del tanque, N_S, y la EM. Los dos conteos comparten la densidad local de muones ρ, que fluctúa de lluvia a lluvia y de estación a estación más allá de Poisson. Un modelo jerárquico mínimo es

$$\rho_i \sim \text{Gamma}\big(\text{media } \mu(\phi_i),\ \text{dispersión } \kappa\big), \qquad N_{U,i} \mid \rho_i \sim \text{Pois}(a_U \rho_i), \qquad N_{S,i} \mid \rho_i \sim \text{Pois}(a_S \rho_i), \tag{8}$$

con

$$\mathcal{L}^{\text{UMD}}_{\text{cens}} = \prod_{i \in S} \int d\rho\, P(\rho \mid \boldsymbol{\vartheta}, \kappa)\, P(n_{U,i} \mid a_U \rho) \sum_{n_S} P(n_S \mid a_S \rho)\, \varepsilon(n_S, \boldsymbol{x}_i) \times \prod_{j \in \bar{S}} \Big[1 - \int d\rho\, P(\rho \mid \boldsymbol{\vartheta}, \kappa)\, \bar{\varepsilon}(a_S \rho, \boldsymbol{x}_j) \Big]. \tag{9}$$

Dos consecuencias: (i) si ρ no fluctuara ($\kappa \to \infty$), N_U y la selección serían independientes dado $\boldsymbol{x}$ y el UMD no tendría sesgo; el sesgo del UMD es proporcional a la sobredispersión de la densidad local, lo que explica que la tesis lo espere menor que en el SD. (ii) Si en los datos no se dispone del conteo UMD de las estaciones no seleccionadas (la tesis indica que no), el segundo producto es igualmente válido, porque sólo requiere saber que la estación existía y no fue seleccionada.

4. Versión bayesiana y parámetros de ruido

La eficiencia ε no se conoce exactamente: se calibra en simulación y depende del modelo hadrónico, del umbral y de la EM. Conviene parametrizarla, por ejemplo con una logística

$$\varepsilon(n, \boldsymbol{x}; \boldsymbol{\eta}) = \sum_{n_{EM}} \sigma(\eta_0 + \eta_1 n + \eta_2 n_{EM})\, P(n_{EM} \mid \boldsymbol{x}; \boldsymbol{\eta}_{EM}), \tag{10}$$

y tratar $\boldsymbol{\eta}$ como parámetros de ruido con un prior $\pi(\boldsymbol{\eta})$ dado por el ajuste a la simulación (donde, a diferencia de los datos, *sí* se conocen N y T de todas las estaciones, incluido `HasStation=False`). El posterior

$$p(\boldsymbol{\vartheta} \mid \text{datos}) \propto \int d\boldsymbol{\eta}\ \mathcal{L}_{\text{cens}}(\boldsymbol{\vartheta}, \boldsymbol{\eta})\, \pi(\boldsymbol{\eta})\, \pi(\boldsymbol{\vartheta}) \tag{11}$$

se muestrea por MCMC; la marginalización sobre $\boldsymbol{\eta}$ propaga automáticamente la incerteza sistemática de la selección a A_1. Para la EM tardía puede usarse el propio dato: la señal total de las estaciones seleccionadas restringe $P(n_{EM} \mid \boldsymbol{x})$, y puede ajustarse simultáneamente una LDF electromagnética con su propia modulación.

5. Prueba con un Monte Carlo de juguete

Configuración. Estaciones con ϕ uniforme; $N \sim \mathrm{Pois}(0.9(1 + 0.07\cos\phi))$; $N_{EM} \sim \mathrm{Pois}(20(1 + 0.33\cos\phi))$, de modo que la EM tardía es aproximadamente la mitad de la temprana, como en la Fig. 6.1.6 de la tesis. La señal del tanque es la suma de una contribución muónica fluctuante (Γ de media 1 VEM por muón) y una EM (Γ de media 0.05 VEM por partícula); la estación se selecciona si supera 1.6 VEM. Con estos parámetros, del lado temprano (tardío) se retiene el 63 % (39 %) de las estaciones, y las retenidas tienen en promedio 1.43 (1.67) muones, cualitativamente como en la tesis (54 %/33 %; 1.49/1.69 en 900–1500 m). La eficiencia $\varepsilon(n, \cos\phi)$ se tabula con una simulación independiente, como se haría con la biblioteca oficial. Se generaron 500 pseudo-experimentos de 15 000 estaciones.

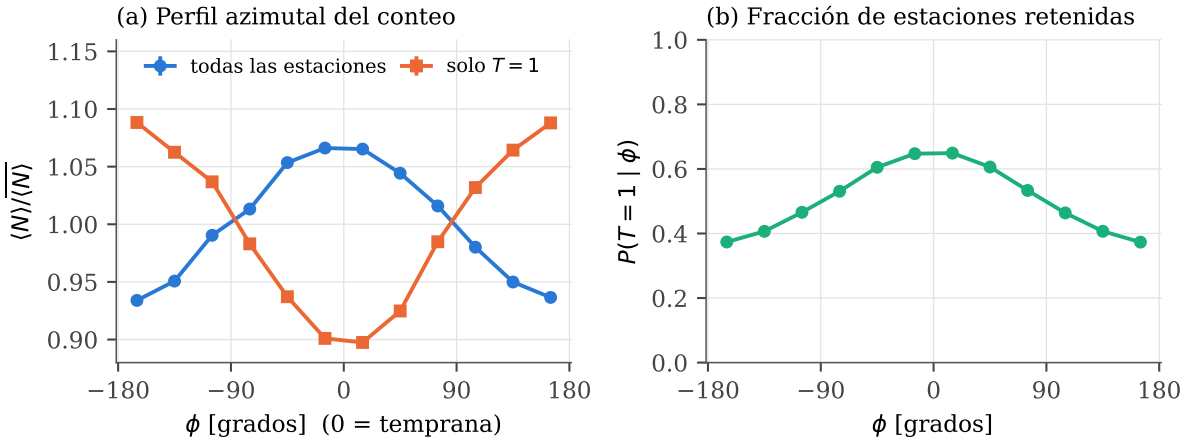


Figura 1: Toy MC. (a) Perfil azimutal del conteo medio normalizado: sobre todas las estaciones (máximo en la región temprana, $A_1 > 0$) y sólo sobre las seleccionadas (máximo en la tardía, $A_1 < 0$). (b) Fracción de estaciones retenidas en función de ϕ.

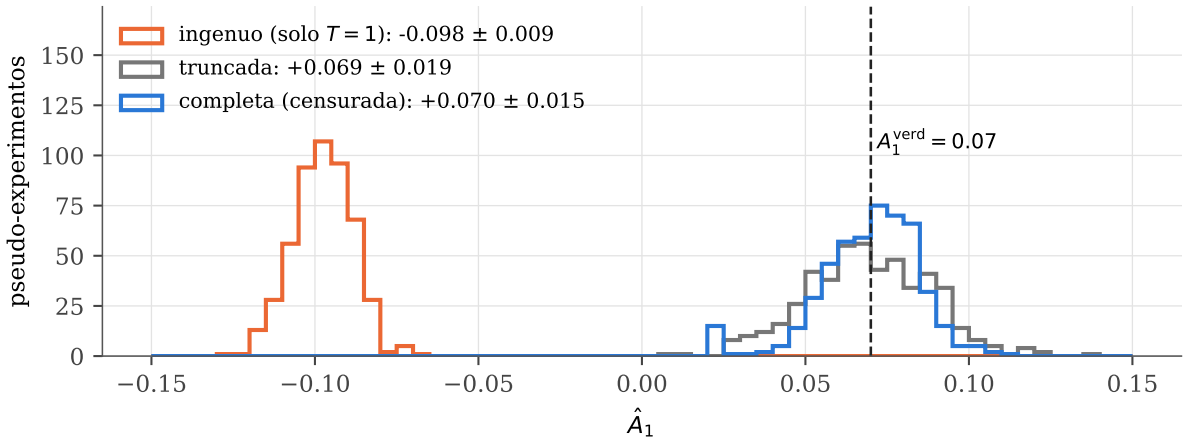


Figura 2: Distribución de $\hat{A}_1$ en 500 pseudo-experimentos para el ajuste ingenuo (sólo estaciones seleccionadas, sin modelar la selección), la verosimilitud truncada (5) y la censurada (6). Línea a trazos: valor verdadero.

Lectura de los resultados.

1. El toy reproduce la inversión de la tesis: el promedio sobre las estaciones seleccionadas da $A_1 \approx -0.10$ con $A_1^{\mathrm{verd}} = +0.07$.

Estimador	$\langle \hat{A}_1 \rangle$	dispersión
Ajuste armónico, todas las estaciones (referencia)	$+0.070$	0.012
Ajuste armónico, sólo seleccionadas (como en la tesis)	-0.095	0.009
Poisson ingenuo, sólo seleccionadas	-0.098	0.009
Verosimilitud truncada	$+0.069$	0.019
Verosimilitud censurada	$+0.070$	0.015
Truncada, ε con EM -15 % / $+15$ %	$+0.004$ / $+0.109$	0.022 / 0.017
Censurada, ε con EM -15 % / $+15$ %	$+0.064$ / $+0.078$	0.015 / 0.018

Tabla 1: Resultados del toy MC ($A_1^{\text{verd}} = 0.07$). Las dos últimas filas usan una eficiencia calibrada con una normalización de la EM errada en ± 15 %, para simular un error de modelo.

2. Las dos verosimilitudes son insesgadas cuando ε es correcta. La censurada es más precisa (0.015 frente a 0.019); el precio respecto del caso ideal sin selección (0.012) es la información perdida en las estaciones no leídas.

3. Frente a un error de ± 15 % en la EM de la eficiencia, la truncada se sesga fuertemente (0.004 a 0.109), mientras que la censurada sólo se corre $\sim$0.006–0.008, menos que su error estadístico. **En la práctica, la censurada es la opción recomendada.**

4. La incerteza obtenida del Hessiano subestima en $\sim$14 % la dispersión real de la censurada (ancho de los *pulls* 1.14); conviene calibrarla con pseudo-experimentos o usar el posterior completo.

6. Plan de validación con la simulación oficial

1. **Calibrar ε.** Con la biblioteca de protón, $30^\circ \le \theta < 40^\circ$, ajustar $P(\texttt{HasStation} \mid N_\mu^{\text{SD}}, N_{EM}, \boldsymbol{x})$ usando todas las estaciones simuladas.

2. **Prueba de cierre.** Aplicar la verosimilitud censurada a las estaciones seleccionadas y verificar que se recupera la curva "todas las estaciones" de la Fig. 6.1.5 de la tesis (en particular $+0.069 \pm 0.016$ en 1200–1350 m, en lugar de -0.124).

3. **Sistemáticos.** Repetir con ε calibrada en hierro y con otro modelo hadrónico (QGSJET-III), y con normalización de la EM y del número de muones variadas, para cubrir el déficit de muones de los modelos.

4. **UMD.** Estimar la sobredispersión κ de la densidad local en simulación y cuantificar el sesgo residual del UMD con el modelo de la Sec. 3.

5. **Datos.** Aplicar la versión censurada usando la lista de estaciones activas por evento.

7. Limitaciones

- **Identificabilidad.** En un problema MNAR la corrección depende enteramente del modelo de selección: con los datos seleccionados no es posible verificar la forma de $\varepsilon(n, \boldsymbol{x})$ para valores de n que casi nunca se seleccionan. La validez descansa en la simulación.

- **T es compuesta.** `HasStation` mezcla el disparo local (T1/T2), la selección del evento (T3, 6T5) y la reconstrucción. Conviene modelar cada etapa por separado, que es justamente lo que la tesis deja abierto. La selección a nivel de evento condiciona además la lluvia completa, aunque ese efecto debería afectar de manera similar a ambas regiones.

- **Dependencia de modelo.** $P(n_{EM} \mid \boldsymbol{x})$ y la relación N_μ–señal vienen de la simulación; el déficit de muones de los modelos hadrónicos entra en ε.
- **Geometría.** El corrimiento del núcleo reconstruido ($\Delta A_1 \simeq -\beta b/r$) es un sesgo distinto y debe corregirse aparte, por ejemplo usando r verdadero en la calibración y propagando b como parámetro de ruido.